

# RESENHA: ‘UTILIZANDO UMA REDE NEURAL ARTIFICIAL PARA APROXIMAÇÃO DA FUNÇÃO DE EVOLUÇÃO DO SISTEMA DE LORENTZ’

Bianca Lara Gomes  
biancalara@gmail.com

## OBJETIVO

O objetivo principal do artigo lido é realizar a aproximação da função de evolução temporal do Sistema de Lorenz utilizando uma Rede Neural Artificial do tipo MLP (Multilayer Perceptron). Além deste objetivo principal, como objetivo específico, apresentam-se os conceitos básicos das Redes Neurais Artificiais (RNAs), um breve histórico da Teoria do Caos e o Sistema de Lorenz. A metodologia adotada na estruturação deste artigo foi definida como bibliográfica e experimental. Atualmente, existe grande interesse nos modelos de redes neurais para resolver problemas não convencionais e complexos, nesse contexto, as Redes Neurais Artificiais têm surgido como alternativa para inúmeras aplicações em diversas áreas do conhecimento.

Os resultados obtidos nos experimentos apontam positivamente para a utilização das RNAs. Espera-se com o artigo incentivar a utilização das RNAs em aplicações complexas em que a aprendizagem, associação, generalização e abstração são necessárias para apoio à tomada de decisão. Concluiu-se que a utilização das RNAs pode ser uma alternativa para resolução de problemas envolvendo aproximação de funções.

## 1. MÉTODOS

A realização da pesquisa está embasada em consultas às fontes bibliográficas e de referencial teórico como: artigos, livros, teses, dissertações e websites com conteúdo sobre Teoria do Caos, Efeito Borboleta e Redes Neurais Artificiais. Utilizou-se, no artigo, uma Rede Neural Artificial (RNA) do tipo MLP (Multilayer Perceptron). As RNAs são consideradas um aproximador universal de funções contínuas (KOVÁCS, 2006). Segundo Russel e Norvig (2013), aprender a aproximar funções é considerado uma tarefa de inferência indutiva, a RNA aprende a representar funções de forma eficiente e útil.

As características das RNAs confirmam a sua aplicação em diversas áreas como: previsão de falência (ITURRIAGA e SANZ, 2015), previsão de volatilidade dos preços do ouro (KRISTJANPOLLER e MINUTOLO, 2015), previsão de máxima e mínima do preço das ações de empresas de distribuição de energia elétrica (LABOISSIERE, FERNANDES e LAGE, 2015), análise de desempenho do mercado acionário (RATH, JAGADEV e NAYAK, 2015), estimativas de vendas (LARRAIN e TURNER, 2014), previsão do absentismo no trabalho (MARTINIANO et al., 2012), previsão do comportamento do tráfego veicular urbano (FERREIRA, 2011), identificação

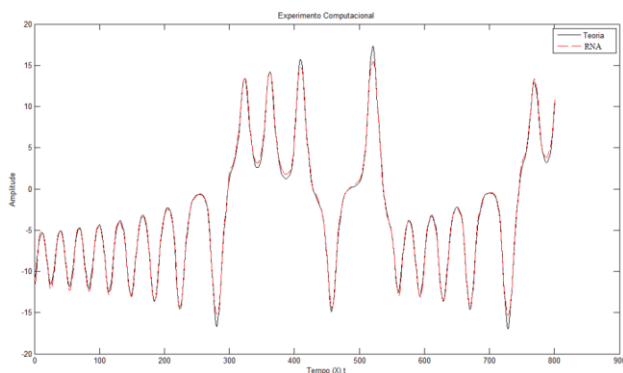
de demonstrações financeiras falsificadas (GAGANIS, 2009).

Outras aplicações também podem ser encontradas em campos diversos como: modelagem, análise de séries temporais, reconhecimento de padrões e processamento de sinais e controle (HAYKIN, 2001; SILVA, SPATTI e FLAUZINO, 2010; BRAGA, CARVALHO e LUDERMIR, 2011).

## 2. RESULTADOS

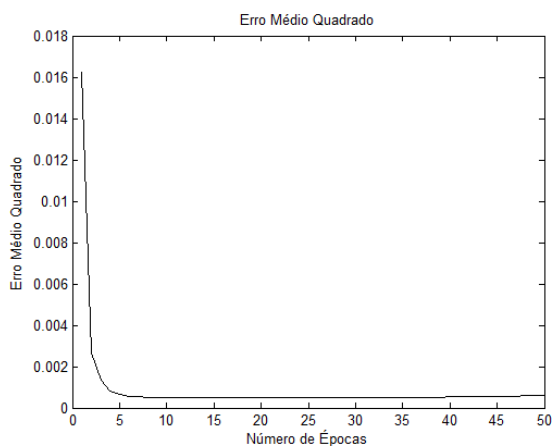
A solução do sistema de Lorenz para  $\sigma = 10$ ,  $r = 28$  e  $b = 8/3$ , a partir da condição inicial  $X(0) = 1$ ,  $Y(0) = 2$ ,  $Z(0) = 3$ . Essa solução é utilizada nos dois experimentos.

Os parâmetros utilizados na RNA MLP no experimento 1: número de neurônios de entrada igual a 15, número de camadas igual a 3, número de neurônios nas camadas ocultas igual a 100, taxa de aprendizagem constante igual a 0,1, fator de momento constante igual a 0, e número máximo de épocas igual a 50. O tempo de processamento foi de 6,4 segundos. A Figura 3 mostra a evolução temporal da variável  $X(t)$  e a aproximação calculada pela RNA.




**Figura 3 – Evolução temporal de  $X(t)$  e a aproximação calculada pela RNA.**

A Figura 4 mostra a curva de aprendizagem experimental (erro médio quadrado) com número máximo de 50 épocas.



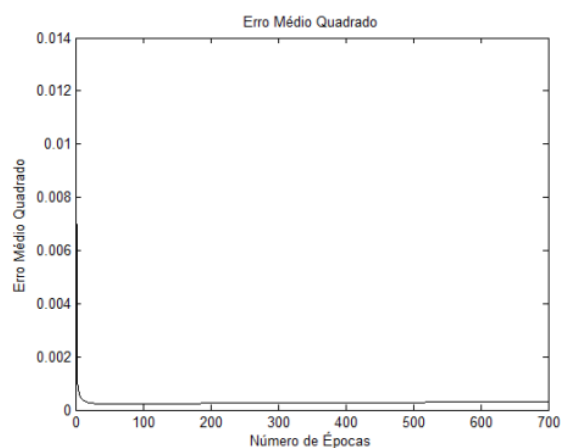
**Figura 4 – Erro Médio Quadrado x 50 épocas.**

Os parâmetros utilizados na RNA MLP no experimento 2: número de neurônios de entrada igual a 25, número de camadas igual a 3, número de neurônios nas camadas ocultas igual a 300, taxa de aprendizagem constante igual a 0,1, fator de momento constante igual a 0,5 e número máximo de épocas igual a 700. O tempo de processamento foi de 157,4 segundos. A Figura 5 mostra a evolução temporal da variável  $X(t)$  e a aproximação calculada pela RNA no experimento 2.



**Figura 5 – Evolução temporal de  $X(t)$  e a aproximação calculada pela RNA.**

A Figura 6 mostra a curva de aprendizagem experimental (erro médio quadrado) com número máximo de 700 épocas.



**Figura 6 – Erro Médio Quadrado x 700 épocas**

### 3. CONCLUSÃO

Observa-se com base nos experimentos realizados com a Rede Neural Artificial, os experimentos apresentaram boa aproximação da função de Evolução Temporal do Sistema de Lorentz. Pode-se concluir que as alterações nos parâmetros da RNA não apresentaram grande variação no resultado, exceto na variação de tempo de processamento.

Os erros médios quadrados nos dois experimentos estabilizaram próximo da trigésima época. As RNAs podem ser utilizadas para resolver numerosa quantidade de problemas reais complexos, entre esses: aproximação de funções, previsão e controle, reconhecimento de voz, reconhecimento ótico de caracteres, reconhecimento de padrões, mineração de dados, classificação etc.

Como estudos futuros pretende-se realizar novos experimentos com outras funções de maior complexidade com o intuito de avaliar outros resultados experimentais. Pretende-se também utilizar outros tipos de RNAs para comparar o desempenho entre as diversas RNAs existentes.